

Современные методы анализа данных и машинного обучения

Тема 11. Лекция 14

Глубинное обучение. Обработка естественного языка

Юрий Саночкин

ysanochkin@hse.ru


НИУ ВШЭ, 2026

Задачи NLP

- Задачи обработки естественного языка — или задачи Natural Language Processing (NLP) — это, без сомнения, самые актуальные и хайповые темы во всем машинном обучении в настоящий момент.


Задачи NLP

- Задачи обработки естественного языка — или задачи Natural Language Processing (NLP) — это, без сомнения, самые актуальные и хайповые темы во всем машинном обучении в настоящий момент.
- Да вы и сами это прекрасно знаете!




Задачи NLP

- Но как такие задачи вообще решать?
- Первый и главный вопрос, с которым мы сталкиваемся, заключается в том, как в принципе следует представить текст компьютеру.




Задачи NLP

- Текст в буквенном виде не может быть нормально обработан машиной, которая всегда должна принимать вход в машиночитаемом формате.




Задачи NLP

- Текст в буквенном виде не может быть нормально обработан машиной, которая всегда должна принимать вход в машиночитаемом формате.
- Машиночитаемый формат — это число или набор чисел, числовой вектор.



Задачи NLP

- Представление текста в виде числового вектора позволит нам обрабатывать текст с помощью методов машинного и, в частности, глубокого обучения.



Векторные представления текста

Векторные представления текста

- Итак, наша задача — представить текстовые строки в виде числовых векторов.

Векторные представления текста

- Итак, наша задача — представить текстовые строки в виде числовых векторов.
- Такие вектора ещё называются эмбедингами (но мы уже знаем этот термин).

Векторные представления текста

- Итак, наша задача — представить текстовые строки в виде числовых векторов.
- Такие вектора ещё называются эмбедингами (но мы уже знаем этот термин).
- Пример эмбедингов для слов:
 - dog [0.033, -0.009, 0.037, 0.068, ..., 0.053]
 - cat [0.067, 0.069, -0.015, -0.0249, ..., 0.0317]
 - home [-0.0004, 0.0199, 0.03, -0.04, ..., -0.031]
 - computer [-0.0016 , 0.0872, -0.0314, -0.0523, ..., 0.0228]
 - love [-0.169, 0.0382, 0.0084, -0.0182, ..., -0.0209]

Векторные представления текста

- Но как же получить подобные вектора?
- Мы разберём несколько подходов.

One-hot представления

One-hot представления

- И первым подходом будет хорошо нам знакомый One-hot.
- One-hot encoding — метод представления объекта в ограниченном словаре, когда значение, соответствующее объекту, равно 1, а все остальные значения в векторном представлении — нулевые.

One-hot представления

- И первым подходом будет хорошо нам знакомый One-hot.
- One-hot encoding — метод представления объекта в ограниченном словаре, когда значение, соответствующее объекту, равно 1, а все остальные значения в векторном представлении — нулевые.
- Примеры:
 - dog: [1, 0, 0, 0, ..., 0]
 - cat: [0, 1, 0, 0, ..., 0]
 - home: [0, 0, 1, 0, ..., 0]
 - computer: [0, 0, 0, 1, ..., 0]
 - love: [0, 0, 0, 0, ..., 1]

One-hot представления

- И первым подходом будет хорошо нам знакомый One-hot.
- One-hot encoding — метод представления объекта в ограниченном словаре, когда значение, соответствующее объекту, равно 1, а все остальные значения в векторном представлении — нулевые.
- В чем проблема этого подхода? Почему использовать его для реальных задач не очень эффективно?


One-hot представления

- И первым подходом будет хорошо нам знакомый One-hot.
- One-hot encoding — метод представления объекта в ограниченном словаре, когда значение, соответствующее объекту, равно 1, а все остальные значения в векторном представлении — нулевые.
- В чем проблема этого подхода? Почему использовать его для реальных задач не очень эффективно?
- Представления, построенные на основе подхода One-hot, к сожалению, никак не учитывают знания о мире и объектах.

Bag-of-Words представления


Bag-of-Words представления

- Bag-of-Words (BoW) — метод представления текста в ограниченном словаре, когда каждому тексту соответствует вектор размерности словаря, являющийся суммой one-hot encodings всех слов в тексте.




Bag-of-Words представления

- Bag-of-Words (BoW) — метод представления текста в ограниченном словаре, когда каждому тексту соответствует вектор размерности словаря, являющийся суммой one-hot encodings всех слов в тексте.
- Примеры:
 - dog and cat are at home: [1, 1, 1, 0, 0, 1, ..., 0]
 - home, home and again home: [0, 1, 3, 1, 0, 0, ..., 0]



Bag-of-Words представления

- Bag-of-Words (BoW) — метод представления текста в ограниченном словаре, когда каждому тексту соответствует вектор размерности словаря, являющийся суммой one-hot encodings всех слов в тексте.
- Такие представления, к сожалению, тоже не учитывают знания о мире и объектах.




Bag-of-Words представления

- Bag-of-Words (BoW) — метод представления текста в ограниченном словаре, когда каждому тексту соответствует вектор размерности словаря, являющийся суммой one-hot encodings всех слов в тексте.
- Такие представления, к сожалению, тоже не учитывают знания о мире и объектах.
- Вдобавок, в случае с BoW, они еще не учитывают порядок слов, что может быть важно в контексте понимания смысла.

Bag-of-Words представления

- Bag-of-Words (BoW) — метод представления текста в ограниченном словаре, когда каждому тексту соответствует вектор размерности словаря, являющийся суммой one-hot encodings всех слов в тексте.
- Такие представления, к сожалению, тоже не учитывают знания о мире и объектах.
- Вдобавок, в случае с BoW, они еще не учитывают порядок слов, что может быть важно в контексте понимания смысла.



Bag-of-Words представления

- Наконец, такие представления имеют огромную размерность (по числу слов в словаре).

Размер словаря (# лемм)	% содержания в ОЕС (Oxford English Corpus)	Примеры лемм
10	25%	the, of, and, to, that, have
100	50%	from, because, go, me, our, well, way
1000	75%	girl, win, decide, huge, difficult, series
7000	90%	tackle, peak, crude, purely, dude, modest
50,000	95%	saboteur, autocracy, calyx, conformist
>1,000,000	99%	laggardly, endobenthic, pomological

TF-IDF

TF-IDF

- Итак, после двух предыдущих подходов имеем проблему: как добавить в модель знание о мире?

TF-IDF

- Итак, после двух предыдущих подходов имеем проблему: как добавить в модель знание о мире?
- Есть большая коллекция разнородных документов — статьи, рассказы, письма, сообщения.
- Можно построить модель, учитывающую частоту появления слов в документах.

TF-IDF

- TF-IDF (Term Frequency — Inverse Document Frequency) — статистическая мера, используемая для оценки важности слова в контексте документа, являющегося частью коллекции документов или корпуса.

TF-IDF

- TF-IDF (Term Frequency — Inverse Document Frequency) — статистическая мера, используемая для оценки важности слова в контексте документа, являющегося частью коллекции документов или корпуса.
- По смыслу этот подход представляет собой следующее: если некоторое слово встречается в каком-либо документе часто, при этом встречаясь редко во всех остальных документах, — данное слово имеет большую значимость для того самого документа; в то же время слова, часто встречающиеся во всех документах, — будут малозначимыми для каждого из них.

TF-IDF

- Математически TF-IDF можем формализовать так:

TF-IDF

- Математически TF-IDF можем формализовать так:

$$\text{tf}(t, d) = \frac{n_t}{\sum_k n_k}; \quad \text{idf}(t, D) = \log \frac{|D|}{|\{d_i \in D | t \in d_i\}|}$$

$$\text{tf-idf}(t, d, D) = \text{tf}(t, d) \times \text{idf}(t, D)$$

TF-IDF

- Математически TF-IDF можем формализовать так:

$$\text{tf}(t, d) = \frac{n_t}{\sum_k n_k}; \quad \text{idf}(t, D) = \log \frac{|D|}{|\{d_i \in D | t \in d_i\}|}$$

$$\text{tf-idf}(t, d, D) = \text{tf}(t, d) \times \text{idf}(t, D)$$

Прокомментируйте все обозначения в формулах.
За что отвечает каждая компонента?

TF-IDF

- Хорошо, разберемся по частям.

TF-IDF

- Хорошо, разберемся по частям.
- TF (term frequency — частота слова) — отношение числа вхождений некоторого слова к общему числу слов документа:

$$\text{tf}(t, d) = \frac{n_t}{\sum_k n_k}$$

TF-IDF

- Хорошо, разберемся по частям.
- TF (term frequency — частота слова) — отношение числа вхождений некоторого слова к общему числу слов документа:

$$\text{tf}(t, d) = \frac{n_t}{\sum_k n_k}$$

- Данная компонента будет показывать важность конкретного слова в конкретном документе.

TF-IDF

- IDF (inverse document frequency — обратная частота документа) — инверсия частоты, с которой некоторое слово встречается в документах коллекции (корпуса):

$$\text{idf}(t, D) = \log \frac{|D|}{|\{d_i \in D | t \in d_i\}|}$$

TF-IDF

- IDF (inverse document frequency — обратная частота документа) — инверсия частоты, с которой некоторое слово встречается в документах коллекции (корпуса):

$$\text{idf}(t, D) = \log \frac{|D|}{|\{d_i \in D | t \in d_i\}|}$$

- Учёт IDF уменьшает и корректирует вес широко употребляемых слов.

TF-IDF

- Таким образом, мера TF-IDF является произведением двух сомножителей:

$$\text{tf-idf}(t, d, D) = \text{tf}(t, d) \times \text{idf}(t, D)$$

TF-IDF

- Таким образом, мера TF-IDF является произведением двух сомножителей:

$$\text{tf-idf}(t, d, D) = \text{tf}(t, d) \times \text{idf}(t, D)$$

- Большой вес в TF-IDF получают слова с высокой частотой в пределах конкретного документа и с низкой частотой употреблений в других документах.

TF-IDF

- Несмотря на всю идилличность вышеописанных концептов, TF-IDF всё ещё имеет ряд проблем. Каких?

TF-IDF

- Несмотря на всю идилличность вышеописанных концептов, TF-IDF всё ещё имеет ряд проблем. Каких?
- Огромная размерность

TF-IDF

- Несмотря на всю идилличность вышеописанных концептов, TF-IDF всё ещё имеет ряд проблем. Каких?
- Огромная размерность
- Не учитывается порядок слов и близость расположения слов

TF-IDF

- Несмотря на всю идилличность вышеописанных концептов, TF-IDF всё ещё имеет ряд проблем. Каких?
- Огромная размерность
- Не учитывается порядок слов и близость расположения слов
 - То есть не учитывается контекст слова. Что в свою очередь во многом является ключевым в задачах NLP.

Векторные представления текста

- Прежде чем обсуждать следующий подход, давайте немного формализуем наши запросы.
- Каким требованиям должно удовлетворять наше новое векторное представление, чтобы оно было принципиально лучше предыдущих подходов?

Требования к векторному представлению

Требования к векторному представлению

- Небольшая размерность

Требования к векторному представлению

- Небольшая размерность
- Учет порядка слов

Требования к векторному представлению

- Небольшая размерность
- Учет порядка слов
- Родственные слова должны иметь близкие значения
 - Бег ~ бежать
 - Ходить ~ ходули
 - Писать ~ описание

Требования к векторному представлению

- Небольшая размерность
- Учет порядка слов
- Родственные слова должны иметь близкие значения
 - Бег ~ бежать
 - Ходить ~ ходули
 - Писать ~ описание
- Близкие по смыслу слова также должны иметь близкие значения
 - Большой ~ огромный
 - Купить ~ приобрести
 - Ананас ~ финик

Семантика языка

You shall know a word
by the company it keeps.

Firth, 1957

Семантика языка


You shall know a word
by the company it keeps.

Firth, 1957

Oculist and eye-doctor...
occur in almost the same environments.
If A and B have almost identical environments
we say that they are synonyms.

Zellig Harris, 1954

Семантика языка



Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.

Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.
- Вы знаете, что такое “tezgüino”? Поднимите руку, кто знает! :)

Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.
- Вы знаете, что такое “tezgüino”? Поднимите руку, кто знает! :)
- Непонятно. Мы не знаем, что это такое...

Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.
- Вы знаете, что такое “tezgüino”? Поднимите руку, кто знает! :)
- Непонятно. Мы не знаем, что это такое...
- Зато! У нас есть несколько примеров употребления этого слова:

Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.
- Вы знаете, что такое “tezgüino”? Поднимите руку, кто знает! :)
- Непонятно. Мы не знаем, что это такое...
- Зато! У нас есть несколько примеров употребления этого слова:
 - a bottle of tezgüino is on the table

Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.
- Вы знаете, что такое “tezgüino”? Поднимите руку, кто знает! :)
- Непонятно. Мы не знаем, что это такое...
- Зато! У нас есть несколько примеров употребления этого слова:
 - a bottle of tezgüino is on the table
 - everybody likes tezgüino

Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.
- Вы знаете, что такое “tezgüino”? Поднимите руку, кто знает! :)
- Непонятно. Мы не знаем, что это такое...
- Зато! У нас есть несколько примеров употребления этого слова:
 - a bottle of tezgüino is on the table
 - everybody likes tezgüino
 - tezgüino makes you drunk

Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.
- Вы знаете, что такое “tezgüino”? Поднимите руку, кто знает! :)
- Непонятно. Мы не знаем, что это такое...
- Зато! У нас есть несколько примеров употребления этого слова:
 - a bottle of tezgüino is on the table
 - everybody likes tezgüino
 - tezgüino makes you drunk
 - we make tezgüino out of corn.

Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.
- Вы знаете, что такое “tezgüino”? Поднимите руку, кто знает! :)
- Непонятно. Мы не знаем, что это такое...
- Зато! У нас есть несколько примеров употребления этого слова:
 - a bottle of tezgüino is on the table
 - everybody likes tezgüino
 - tezgüino makes you drunk
 - we make tezgüino out of corn.
- Теперь мы знаем, что это такое, верно? :)

Семантика языка

- Давайте рассмотрим еще один пример в контексте семантики.
- Вы знаете, что такое “tezgüino”? Поднимите руку, кто знает! :)
- Непонятно. Мы не знаем, что это такое...
- Зато! У нас есть несколько примеров употребления этого слова:
 - a bottle of tezgüino is on the table
 - everybody likes tezgüino
 - tezgüino makes you drunk
 - we make tezgüino out of corn.
- Теперь мы знаем, что это такое, верно? :)

	context			
	1.	2.	3.	4.
tezgüino	1	1	1	1
loud	0	0	0	0
motor oil	1	0	0	1
tortillas	0	1	0	1
wine	1	1	1	0


Count-based methods

Count-based methods

- Основная идея заключается в том, чтобы добавить информацию о контексте в векторные представления.

Count-based methods

- Основная идея заключается в том, чтобы добавить информацию о контексте в векторные представления.



Count-based methods

- Мы часто говорим про контекст слова. А что вообще понимается под «контекстом» с формальной точки зрения?

Count-based methods

- Мы часто говорим про контекст слова. А что вообще понимается под «контекстом» с формальной точки зрения?
- Контекст слова — это n слов влево и вправо от заданного слова


Count-based methods

- Мы часто говорим про контекст слова. А что вообще понимается под «контекстом» с формальной точки зрения?
- Контекст слова — это n слов влево и вправо от заданного слова
 - Контекст слова слева — это n слов до заданного слова
 - Контекст слова справа — это n слов после заданного слова

Count-based methods

- Мы часто говорим про контекст слова. А что вообще понимается под «контекстом» с формальной точки зрения?
- Контекст слова — это n слов влево и вправо от заданного слова
 - Контекст слова слева — это n слов до заданного слова
 - Контекст слова справа — это n слов после заданного слова
- Ещё одно важное понятие — это совстречаемость.
- Совстречаемость $N(w, c)$ — число раз, которое слово w встретилось в контексте c .

Count-based methods



PMI и PPMI

PMI и PPMI

- Pointwise Mutual Information (PMI) — это как раз один из подходов, реализующийся в рамках Count-based methods, которые мы только что обсуждали.

PMI и PPMI

- Pointwise Mutual Information (PMI) — это как раз один из подходов, реализующийся в рамках Count-based methods, которые мы только что обсуждали.
- PMI оценивает вероятность двух событий произойти, если бы события были независимыми:

$$\text{PMI}(\mathbf{w}, c) = \log \frac{P(\mathbf{w}, c)}{P(\mathbf{w})P(c)} = \log \frac{N(\mathbf{w}, c)|(\mathbf{w}, c)|}{N(\mathbf{w})N(c)}$$

PMI и PPMI

- Отрицательные значения PMI соответствуют событиям, которые одновременно происходят реже, чем мы предполагаем. Поэтому рассматривается positive PMI:

$$\text{PPMI}(w, c) = \max(0, \text{PMI}(w, c))$$

PMI и PPMI

- Отрицательные значения PMI соответствуют событиям, которые одновременно происходят реже, чем мы предполагаем. Поэтому рассматривается positive PMI:

$$\text{PPMI}(w, c) = \max(0, \text{PMI}(w, c))$$

- Если $P(w)$ маленькое, а $P(w, c)$ большое, то вероятнее всего, w и c представляют собой единый связный концепт.

Word2vec

Word2vec

- В настоящий момент Word2vec является одним из самых распространенных и одним из самых эффективных — с точки зрения затрат/качества — подходов в рамках получения текстовых представлений и эмбедингов.

Word2vec

- В настоящий момент Word2vec является одним из самых распространенных и одним из самых эффективных — с точки зрения затрат/качества — подходов в рамках получения текстовых представлений и эмбедингов.
- Идея: обучить векторные представления предсказывать контекст.

Word2vec

- В настоящий момент Word2vec является одним из самых распространенных и одним из самых эффективных — с точки зрения затрат/качества — подходов в рамках получения текстовых представлений и эмбеддингов.
- Идея: обучить векторные представления предсказывать контекст.
- Реализация по шагам:

Word2vec

- В настоящий момент Word2vec является одним из самых распространенных и одним из самых эффективных — с точки зрения затрат/качества — подходов в рамках получения текстовых представлений и эмбедингов.
- Идея: обучить векторные представления предсказывать контекст.
- Реализация по шагам:
 1. Собрать большой корпус текста.

Word2vec

- В настоящий момент Word2vec является одним из самых распространенных и одним из самых эффективных — с точки зрения затрат/качества — подходов в рамках получения текстовых представлений и эмбеддингов.
- Идея: обучить векторные представления предсказывать контекст.
- Реализация по шагам:
 1. Собрать большой корпус текста.
 2. Двигаясь скользящим окном по тексту, для каждого (центрального) слова из корпуса текста:

Word2vec

- В настоящий момент Word2vec является одним из самых распространенных и одним из самых эффективных — с точки зрения затрат/качества — подходов в рамках получения текстовых представлений и эмбедингов.
- Идея: обучить векторные представления предсказывать контекст.
- Реализация по шагам:
 1. Собрать большой корпус текста.
 2. Двигаясь скользящим окном по тексту, для каждого (центрального) слова из корпуса текста:
 - для каждого слова из контекста посчитать вероятности встретиться в контексте центрального слова;

Word2vec

- В настоящий момент Word2vec является одним из самых распространенных и одним из самых эффективных — с точки зрения затрат/качества — подходов в рамках получения текстовых представлений и эмбеддингов.
- Идея: обучить векторные представления предсказывать контекст.
- Реализация по шагам:
 1. Собрать большой корпус текста.
 2. Двигаясь скользящим окном по тексту, для каждого (центрального) слова из корпуса текста:
 - для каждого слова из контекста посчитать вероятности встретиться в контексте центрального слова;
 - обновить вектора, чтобы увеличить эти вероятности.

Word2vec

- Оптимизируем Negative Log-Likelihood:

$$\text{Loss} = J(\theta) = -\frac{1}{T} \log L(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m, \\ j \neq 0}} \log P(w_{t+j} | w_t, \theta)$$

agrees with our
plan above



go over text



with a sliding
window



compute probability of the
context word given the central

Word2vec

- Оптимизируем Negative Log-Likelihood:

$$\text{Loss} = J(\theta) = -\frac{1}{T} \log L(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m, \\ j \neq 0}} \log P(w_{t+j} | w_t, \theta)$$

Прокомментируйте все
обозначения в формуле

agrees with our
plan above



go over text



with a sliding
window



compute probability of the
context word given the central

Word2vec


- Вероятности считаем следующим образом:

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

Dot product: measures similarity of o and c
Larger dot product = larger probability

Normalize over entire vocabulary
to get probability distribution

Word2vec



Word2vec

- Word2Vec имеет две реализации:
- Skip-gram — по центральному слову предсказывает контекст:
 - на вход подается one-hot представление слова в словаре размера N
 - слой Embedding — это матрица $N \times P$ (размерность векторных представлений)
 - на выходе вектор (размерности $N \times 1$) вероятностей для каждого слова из словаря принадлежать контексту входного (центрального) слова.

Word2vec

- Word2Vec имеет две реализации:
- CBOW (Continuous bag-of-words) — по контексту предсказывает центральное слово:
 - на вход подается one-hot представление слова в словаре размера N
 - слой Embedding — это матрица $N \times P$ (размерность векторных представлений)
 - на выходе вектор (размерности $N \times 1$) распределения вероятностей искомого слова в словаре.

Word2vec

- Word2Vec имеет две реализации:
- CBOW (Continuous bag-of-words) — по контексту предсказывает центральное слово:
 - на вход подается one-hot представление слова в словаре размера N
 - слой Embedding — это матрица $N \times P$ (размерность векторных представлений)
 - на выходе вектор (размерности $N \times 1$) распределения вероятностей искомого слова в словаре.

А как мы само векторное представление слова-то получим?
То есть, другими словами, как решим изначальную задачу?

GloVe

GloVe

- GloVe (Global Vectors for Word Representation) представляет собой некоторое объединение Count-based и Word2vec подходов.

GloVe

- GloVe (Global Vectors for Word Representation) представляет собой некоторое объединение Count-based и Word2vec подходов.
- Идея: использовать глобальную статистику по корпусу для обучения векторных представлений.

GloVe

- GloVe (Global Vectors for Word Representation) представляет собой некоторое объединение Count-based и Word2vec подходов.
- Идея: использовать глобальную статистику по корпусу для обучения векторных представлений.
- Аналогично как в word2vec, используются вектора целевого слова и контекста, но дополнительно добавляются еще скалярные bias вектора.


GloVe

context vector word vector bias terms (also learned)

$$J(\theta) = \sum_{w,c \in V} \underbrace{f(N(w, c))}_{\text{weighting function}} \cdot (u_c^T v_w + b_c + \overline{b}_w - \log N(w, c))^2$$

Weighting function to:

- penalize rare events
- not to over-weight frequent events



$$\begin{cases} (x/x_{max})^\alpha & \text{if } x < x_{max}, \\ 1 & \text{otherwise.} \end{cases}$$

$$\alpha = 0.75, x_{max} = 100$$

fastText

fastText


- Еще один интересный подход — это подход fastText.
- Идея: добавить возможность получать вектора для out-of-vocabulary слов, для которых не будут работать ни word2vec, ни GloVe.

fastText

- Еще один интересный подход — это подход fastText.
- Идея: добавить возможность получать вектора для out-of-vocabulary слов, для которых не будут работать ни word2vec, ни GloVe.
- Для этого предлагается использовать subword модель, то есть рассматривать n-граммы, а не слова.
- Обычно берут от 3-грамм до 6-грамм и размерность 300.


fastText

- Еще один интересный подход — это подход fastText.
- Идея: добавить возможность получать вектора для out-of-vocabulary слов, для которых не будут работать ни word2vec, ни GloVe.
- Для этого предлагается использовать subword модель, то есть рассматривать n-граммы, а не слова.
- Обычно берут от 3-грамм до 6-грамм и размерность 300.



fastText

- Еще один интересный подход — это подход fastText.
- Идея: добавить возможность получать вектора для out-of-vocabulary слов, для которых не будут работать ни word2vec, ни GloVe.
- Для этого предлагается использовать subword модель, то есть рассматривать n-граммы, а не слова.
- Обычно берут от 3-грамм до 6-грамм и размерность 300.



Word	Length(n)	Character n-grams
eating	3	<ea, eat, ati, tin, ing, ng>
eating	4	<eat, eati, atin, ting, ing>
eating	5	<eati, eatin, ating, ting>
eating	6	<eatin, eating, ating>

fastText

- Реализовывать это будем следующим образом.

fastText

- Реализовывать это будем следующим образом.
- Собрать словарь n-грамм

fastText

- Реализовывать это будем следующим образом.
- Собрать словарь n-грамм
 - Для каждого слова обозначить начало и конец: <eating>

fastText

- Реализовывать это будем следующим образом.
- Собрать словарь n-грамм
 - Для каждого слова обозначить начало и конец: <eating>
 - Сгенерировать все n-граммы слова, например, для n=3: <ea, eat, ati, tin, ing, ng>

fastText

- Реализовывать это будем следующим образом.
- Собрать словарь n-грамм
 - Для каждого слова обозначить начало и конец: <eating>
 - Сгенерировать все n-граммы слова, например, для n=3: <ea, eat, ati, tin, ing, ng>
 - Для ограничения потребляемой памяти, используют bucket — учат не сразу все уникальные n-граммы, а только часть (обычно bucket ~ миллион)

fastText

- Обучить skip-gram модель, используя негативный сэмплинг

fastText

- Обучить skip-gram модель, используя негативный сэмплинг
 - Инициализировать случайно векторные представления всех n-грам словаря

fastText

- Обучить skip-gram модель, используя негативный сэмплинг
 - Инициализировать случайно векторные представления всех n-грам словаря
 - Для каждого центрального слова в тексте:
 - посчитать векторное представление, сложив вектора всех n-грам
 - посчитать вектора контекста слова
 - центральное слово образует позитивный пример вместе с каждым словом из контекста — паре векторов соответствует целевое значение 1
 - на каждый позитивный пример сэмплировать по 5 негативных примеров: случайно выбрать слова из словаря с вероятностями пропорциональными корню квадратному из частоты встречаемости
 - сопоставить позитивному примеру 1, а негативному — 0.

fastText

- Обучить skip-gram модель, используя негативный сэмплинг
 - Наконец, после всех проделанных действий, обновить значения векторных представлений, максимизируя скалярное произведение векторов позитивных примеров и минимизируя скалярное произведение векторов негативных примеров.

CoVe


- И последний подход, который мы разберем, — это подход CoVe.

CoVe


- И последний подход, который мы разберем, — это подход CoVe.
- Двухслойная двунаправленная LSTM — рекуррентная нейронная сеть, с которой мы еще подробно разберемся позднее, на семинарах — обучается как энкодер в модели машинного перевода, а затем этот энкодер используется для получения векторных представлений для решения других задач.

CoVe

a)



b)



Векторные представления текста

- Наконец, последний вопрос, которым нам нужно задаться, — как оценивать полученные векторные представления?
- Ваши предложения?

Векторные представления текста


- Наконец, последний вопрос, которым нам нужно задаться, — как оценивать полученные векторные представления?
- Ваши предложения?
- Внутренняя оценка — оцениваются свойства векторных представлений. Например:
 - близость векторных представлений похожих слов (есть бенчмарки)
 - аналогичность зависимостей между парами слов (есть бенчмарки)
 - похожесть векторных представлений одинаковых слов на разных языках

Векторные представления текста


- Наконец, последний вопрос, которым нам нужно задаться, — как оценивать полученные векторные представления?
- Ваши предложения?
- Внутренняя оценка — оцениваются свойства векторных представлений. Например:
 - близость векторных представлений похожих слов (есть бенчмарки)
 - аналогичность зависимостей между парами слов (есть бенчмарки)
 - похожесть векторных представлений одинаковых слов на разных языках
- Внешняя оценка — оценивается качество решения задач на основе векторных представлений.

Векторные представления текста

Country and Capital Vectors Projected by PCA



Word2Vec



GloVe